

PROCESAMIENTO DE IMÁGENES BIOMÉDICAS
INSTITUTO TECNOLÓGICO DE BUENOS AIRES

Trabajo Práctico cuatrimestral
“Detección de patologías oftalmológicas
mediante algoritmo de machine learning”

Profesores:

Tomás, Roberto Sebastián
Griffa, Guillermina
Tenas Vai, Priscilla

Grupo 1:

Gatti, Martín
Guirula, Lucía
Fernandez Bettelli, Luciana

Legajos:

59712
60313
60576

Fecha de entrega: 27/06/2023

Índice

1. Introducción	1
2. Marco Teórico	1
3. Materiales y Métodos	4
3.1. Preprocesamiento	4
3.2. Segmentación	4
3.3. Extracción de características	7
3.4. Aplicación de Machine Learning	7
4. Resultados	8
5. Conclusión	11
6. Anexo: Interfaz gráfica	12
7. Bibliografía	15

1. Introducción

La salud ocular es un aspecto fundamental de nuestro bienestar general, y el diagnóstico temprano de enfermedades oftalmológicas desempeña un papel crucial en la preservación de nuestra visión. Dos de estas enfermedades, la retinopatía diabética (RD) y la neovascularización coroidea (NVC), representan una amenaza significativa para la salud en todo el mundo.

La retinopatía diabética afecta a millones de personas en todo el mundo y es responsable del 2,6 % de los casos de ceguera a nivel global (Castillo-Otí et al., 2020). Esta enfermedad, que se desarrolla como una complicación de la diabetes, causa un daño importante en distintas zonas del globo ocular, particularmente en los vasos sanguíneos.

Por otro lado, la neovascularización coroidea es una complicación común de la miopía patológica, una condición en la cual el ojo tiene una forma elongada y la visión de lejos se ve afectada. Una vez que se desarrolla la neovascularización coroidea miópica (NVCm), la mayoría de los ojos afectados experimentan una progresión hacia la atrofia macular, lo que resulta en una pérdida de visión irreversible (Zhu et al., 2016).

Ante estas estadísticas alarmantes, es evidente que la detección temprana y el diagnóstico preciso de la retinopatía diabética y la neovascularización coroidea son fundamentales. La identificación oportuna de estos trastornos permite a los profesionales de la salud ocular implementar tratamientos y estrategias de manejo efectivos para preservar la visión y mejorar la calidad de vida de los pacientes.

En este trabajo se implementaron diferentes técnicas de mejoramiento y segmentación de imágenes retinales para poder extraer luego características de las mismas e implementar un algoritmo de machine learning que pueda brindar a los profesionales oftalmológicos una sugerencia del diagnóstico del paciente tratado.

2. Marco Teórico

La retinopatía diabética es una enfermedad ocular causada por la diabetes. Los vasos sanguíneos dañados y los nuevos anormales pueden causar pérdida de la visión. Esta enfermedad ocurre porque los niveles altos de azúcar en la sangre causan daño a los vasos sanguíneos en la retina, estos vasos sanguíneos pueden hincharse y tener fugas de líquido o también pueden cerrarse e impedir que la sangre fluya. Otras veces, se generan nuevos vasos sanguíneos anormales en la retina. Todos estos cambios pueden hacerle perder la visión. (Boyd, 2022)




Figura 1: Retinopatía Diabética

La enfermedad ocular diabética consiste en dos etapas principales.

La primera etapa se denomina retinopatía diabética no proliferativa, NPDR. Durante esta muchos vasos sanguíneos pequeños sufren pérdidas y hacen que la retina se hinche. Cuando se hincha la mácula, se denomina edema macular. Esta es la razón más común por la que la gente con diabetes pierde la visión. Además, los vasos sanguíneos en la retina pueden cerrarse. Esto se llama isquemia macular y cuando eso sucede, la sangre no puede llegar a la mácula. En algunos casos, se pueden formar pequeñas partículas en la retina, llamadas exudados.(Boyd, 2022)

La segunda etapa se denomina retinopatía diabética proliferativa (PDR). Esta es la etapa más avanzada de la enfermedad ocular diabética. Se produce cuando la retina comienza a desarrollar nuevos vasos sanguíneos. Esto se denomina neovascularización. Estos vasos nuevos frágiles a menudo sangran hacia el vítreo. Si sangran mucho, puede que bloqueen toda la visión. Estos vasos sanguíneos nuevos pueden desarrollar cicatrices. El tejido cicatrizante puede causar problemas con la mácula o derivar en un desprendimiento de retina. La retinopatía diabética proliferativa es muy grave y puede provocar la pérdida de visión tanto central como la periférica (lateral).(Boyd, 2022).

Por otro lado, la neovascularización coroidea es una condición ocular caracterizada por el crecimiento anormal de nuevos vasos sanguíneos en la coroides, especialmente en personas con miopía patológica. Estos nuevos vasos sanguíneos son frágiles y propensos a sangrar y filtrar líquido en la retina, lo que puede causar edema macular y pérdida irreversible de la visión. Los factores que desencadenan este proceso no se comprenden completamente, pero se cree que la falta de oxígeno en la retina, la inflamación y los factores de crecimiento anormales desempeñan un papel importante.



Figura 2: Neovascularización

El diagnóstico de la neovascularización coroidea se realiza mediante exámenes oftalmológicos especializados, como la angiografía con fluoresceína, que permite visualizar los vasos sanguíneos anormales en la coroides. El tratamiento principal para esta condición es la terapia antiangiogénica, que consiste en la administración de medicamentos que inhiben el crecimiento de los vasos sanguíneos anormales y reducen la filtración de líquido en la retina. Otros enfoques terapéuticos, como la terapia con láser o la cirugía, también pueden considerarse en casos específicos. Particularmente en este trabajo, se utilizará el aspecto de que una neovascularización puede avanzar a una situación de aparición de vasos sanguíneos anormales al rededor del disco óptico y vasos retinianos, además de que en esta instancia se producen exudados de mayor tamaño.

3. Materiales y Métodos

Como punto de inicio, se decidieron investigar las características de las enfermedades que se incluyeron en el proyecto. En base a este objetivo, se utilizó la página StarRetinal, para obtener diferentes particularidades asociadas a las patologías, las cuales terminaron siendo exudados de la fovea y sobre ramificación de los vasos sanguíneos.

A la par de la búsqueda de estas características, se investigó por una base de datos de donde poder obtener las imágenes sobre las cuales se aplicarán los algoritmos para obtención de parámetros. Particularmente para este trabajo, se utilizó la base de datos STARE, la cual contaba con un set de 400 imágenes, de las cuales se seleccionaron las correspondientes con las enfermedades descriptas anteriormente, además de aquellas correspondientes a una retina sana.

Además, teniendo en cuenta el hecho de que va a haber aspectos distintivos tanto en los patrones básicos de las imágenes como diferencias rotundas y aleatorias en ciertas áreas de la imagen donde se encuentren las manchas, se decidió hacer un análisis de texturas.

Para lograr esto, se realizaron los siguientes pasos: Preprocesamiento, Segmentación, Extracción de características (Análisis de Texturas).

3.1. Preprocesamiento

Se inició desde una base de datos de imágenes retinales a color, por lo que el punto de partida fue elegir las capas de la imagen con la que se iba a trabajar. Se seleccionó la verde, debido a la relación de intensidades de los píxeles y teniendo en cuenta cuales servían más para realzar y localizar los caracteres patogénicos. Luego, se procedió a eliminar el fondo de la imagen con una máscara que selecciona los píxeles dentro de un círculo en la imagen original y establece los píxeles fuera del círculo en cero, generando así un fondo negro.

Una vez hecho esto, con el objetivo de una efectiva visualización, se procedió a la etapa de mejoramiento. Un primer acercamiento fue realizar un ecualizado, sin embargo esto aumentaba mucho los niveles de gris e interfería mucho luego con la segmentación del disco óptico y la mancha de exudado, por lo que se terminó descartando. En su lugar, siguiendo los procedimientos descritos por Sreng et al. (2018), se aplicó un filtrado gamma, lo cual es muy común de hacer en el manejo de imágenes de retina para corregir la respuesta no lineal de los dispositivos de obtención y visualización.

El filtro gamma es una transformación no lineal que se aplica a una imagen para ajustar su brillo y contraste, basándose en una función matemática llamada corrección gamma, controlando como se redistribuyen los píxeles en la imagen.

Posterior a esto, una vez con las capas de las imágenes seleccionadas y el filtrado gamma ya realizado, se procedió al proceso de segmentación.

3.2. Segmentación

Para el correcto aislamiento de las manchas y vasos se usaron dos procesos muy distintos.

Para la segmentación de los exudados, en una primera instancia se utilizó un algoritmo de *top hat* morfológico, nuevamente aplicando los procedimientos descritos por Sreng et al. (2018) en su estudio. *Top hat* se basa en utilizar un kernel particular para realizar la operación de apertura (dilatación seguida de una erosión). Este algoritmo arrojaba resultados efectivos en ciertos casos, pero en varios otros no lograba imitar la forma de las manchas, por lo cual terminó siendo descartado.




Figura 3: Ejemplo de aplicación Top Hat

Por ende se terminó realizando un umbralizado de la imagen, aplicando un valor umbral que se determinó de forma empírica y también teniendo en cuenta que los valores de intensidad eran bastante diferentes en las zonas donde aparecían las manchas y en el disco óptico.

Luego, para la segmentación del árbol vascular retinal se intentaron diversas aproximaciones con el objetivo de poder segmentar los vasos de forma correcta.

Inicialmente, se intentó con la aplicación de un filtro Kirsch (Syna Sreng et al., 2017), el cual consiste en un operador que utiliza kernels en ocho direcciones diferentes y luego discriminando valores dentro de los obtenidos para así obtener los "bordes óptimos". Se obtenía una imagen realmente prometedora, donde se pueden reconocer realmente muy bien los vasos, sin embargo, era muy sensible a las variaciones de grises del humor vítreo, agregando ruido que no se pudo extraer.




Figura 4: Detección de Bordes con Kirsch

A su vez también se intentó con un algoritmo de técnicas mixtas, muy usado en segmentación de manchas y vasos en imágenes oculares, combinando una detección de bordes a través del algoritmo de Kirsch inicialmente, seguido de una umbralización y una operación de apertura para eliminar regiones pequeñas y conexiones no deseadas. Una vez hecho esto, encuentra las componentes conectadas y se lo aplica a la imagen inicial como una máscara. Este algoritmo arrojaba resultados

efectivos en ciertos casos, pero en varios otros no lograba imitar la forma de los vasos, por lo cual también fue desechado.




Figura 5: Detección correcta de Vasos




Figura 6: Detección incorrecta de Vasos

Finalmente, se procedió a realizar un realce de bordes sumado a una transformada de Hough para detectar de forma correcta las líneas asociadas con las paredes de los vasos, filtrando posteriormente aquellas que no logran una longitud considerable. Cabe destacar que esto devuelve una aproximación de la estructura anatómica venosa, sin embargo sirve como para detectar el patrón que los mismos describen en la imagen retinal.




Figura 7: Detección de Vasos con Hough

Una vez efectuados estos dos algoritmos, los cuales nos devolvían tanto el área de los exudados como una aproximación de las venas, se procedió a efectuar el análisis de texturas.

Una aclaración a tener en cuenta es que debido a que la imagen no es un círculo perfecto, y está contenida dentro de una especie de "marco" (lo cual es producto de la técnica de fondo de ojo) todos los algoritmos fueron efectuados en un área circular predefinida (aprovechando que todas las imágenes tenían las mismas dimensiones), de modo tal que se evalúen únicamente los píxeles perteneciente al globo ocular y que el algoritmo no interactúe con el fondo negro.

3.3. Extracción de características

Como se mencionó anteriormente, la extracción de características constó de la caracterización de los vasos y los exudados, sumado al análisis de texturas de cada imagen.

Para el análisis de texturas, se utilizó una matriz de GLCM, que se diferencia de la matriz de coocurrencia que vimos en la cátedra únicamente en que ésta utiliza una máscara de argumento para poder realizar el análisis de texturas en la segmentación. Se decidió que sería más efectivo simplemente utilizar la máscara circular descrita anteriormente para que se comparen los atributos correspondientes a toda la imagen ocular. Los parámetros tomados en cuenta fueron la energía (medida de uniformidad de la imagen), entropía (atributo asociado a la aleatoriedad de los niveles de gris) y auto correlación (parámetro usado para medir la relación entre los píxeles de una imagen en particular).

Para la caracterización de los vasos se utilizó la transformada de Hough, que nos permitía obtener una imagen estimativa binarizada. A ésta, se le calculó el área de los vasos. Finalmente, para las manchas, se aplicó el algoritmo de umbralizado, y se le calculó el área a la imagen binarizada que devolvía.

3.4. Aplicación de Machine Learning

Una vez efectuada la recolección de las características clasificadas como informativas o relevantes, se procedió con la realización de un clasificador, con el objetivo de que se le ingrese una imagen (perteneciente al grupo seleccionado previamente) y pueda detectar si la misma cuenta con alguna de las patologías (diferenciándolas) o si es perteneciente a una retina sana. Las características

utilizadas fueron el área de las manchas y vasos, además de los atributos de Entropía, Energía y Autocorrelación.

Se utilizó un algoritmo de K-Nearest Neighbours para poder realizar la predicción. En este algoritmo, los objetos se clasifican según la mayoría de los vecinos más cercanos. Dado un nuevo objeto, el algoritmo busca los k vecinos más cercanos en el conjunto de entrenamiento y asigna al nuevo objeto la clase que predomine entre esos vecinos.

4. Resultados

El desempeño del algoritmo, como se puede observar en los gráficos a continuación, fue efectivo en la mayoría de los casos, confundiéndose 1 sola vez entre un ojo sano y uno enfermo, y 3 veces entre enfermedades, dentro de un total de 26 datos, brindando un área bajo la curva ROC de 0.95, lo cual se considera efectivo.




Figura 8: Matriz de confusión de kNN




Figura 9: Curva ROC de kNN

Debido a la distribución de los resultados anteriores, y en búsqueda de una diferenciación más marcada en los puntos de las clases, se realizó un análisis de componentes principales (PCA). En lo que respecta a los resultados del mismo, se puede observar que los puntos que presentan una mayor diferencia son los pertenecientes a la Neovascularización Coroidea, lo cual puede deberse a que las imágenes que presentaban esta patología contaban con grandes áreas de exudados, lo cual influenciaba tanto a los parámetros del análisis de texturas como las áreas de vasos y manchas. Por otro lado, la similitud en la ubicación de los puntos asociados a Retinopatía Diabética y Sanos puede deberse a que los exudados en esta última patología están distribuidos en zonas particulares pero son pequeños, por lo que tal vez el algoritmo puede llegar a confundir el tamaño del área de estos con el disco óptico de las sanas. Sin embargo, no se pudo lograr un análisis en profundidad de los gráficos.




Figura 10: Componentes principales de las características utilizadas en kNN




Figura 11: Características utilizadas en kNN

5. Conclusión

Para finalizar y a modo de resumen, en este trabajo se exploraron las características asociadas a diferentes enfermedades oculares utilizando imágenes retinianas. Se aplicaron técnicas de procesamiento de imágenes y análisis de texturas para extraer información relevante de las imágenes y realizar una clasificación.

A modo de conclusión, se puede decir que este enfoque de análisis de imágenes retinianas combinado con técnicas de procesamiento de imágenes y análisis de texturas ofrece una forma prometedora de detectar y clasificar enfermedades oculares. Esto puede ser útil en la detección temprana y seguimiento de enfermedades, permitiendo una intervención médica oportuna.

Posibles mejoras a futuro podrían ser la exploración de otros algoritmos de segmentación y extracción de características, así como la incorporación de técnicas de aprendizaje automático más avanzadas, de modo tal que se puedan mejorar aún más la precisión y robustez del clasificador. Además, se podría considerar la inclusión de más características relevantes y explorar la posibilidad de utilizar conjuntos de datos más grandes y diversos para entrenar y evaluar el modelo.

6. Anexo: Interfaz gráfica

La serie de pasos descripta anteriormente se puede ver representada de una forma más clara y concisa en el siguiente flujograma:




Figura 12: Flujograma

A su vez, se desarrolló una interfaz gráfica que permite a los médicos cargar los datos de los pacientes: Nombre y apellido, sexo, documento de identidad, sexo, diagnóstico y observaciones. Además le va a permitir cargar una imagen, ver las capas de colores correspondientes a la misma, visualizar tanto la corrección Gamma y el filtrado de Kirsch y los valores obtenidos de su caracterización. Luego, a través del botón diagnosticar nos va a decir que patología sugiere el algoritmo de Machine Learning con los gráficos explicados anteriormente. Por último, se va a poder descargar un archivo de tipo pdf, con los datos del paciente, el diagnóstico sugerido, los valores de características adquiridas y los valores promedios de la base de datos para que el profesional de la salud pueda hacer una comparación directa.

Las imágenes de la interfaz correspondientes a dichas pantallas se pueden ver a continuación.

La imagen muestra una ventana de software titulada 'MainWindow' con una barra de navegación superior que contiene los botones: 'Datos paciente', 'Cargar Imagen', 'Imagen original', 'Caracterizar', 'Diagnóstico' y 'Guardar'. El formulario principal está dividido en dos columnas. La columna izquierda contiene los campos de entrada con sus respectivos labels: 'Nombre y apellido', 'Documento de identidad', 'Fecha de nacimiento', 'Sexo', 'Diagnóstico' y 'Observaciones'. La columna derecha muestra los valores ingresados: 'Lucia Guirula', '42666777', '8/25/1999', 'Femenino', 'Diabetes' y 'Vascularización anómala'. El campo de 'Observaciones' es un área de texto más grande.

Figura 13: Ingreso de datos




Figura 14: Visualización de imágenes




Figura 15: Características de la imagen





Figura 16: Diagnóstico sugerido y gráficos

Informe oftalmológico

Nombre y apellido: Lucia Guirula
Documento de identidad: 42666777
Fecha de nacimiento: 25/08/1999
Sexo: Femenino
Diagnóstico: Diabetes
Diagnóstico sugerido mediante algoritmo: Retinopatía Diabética
Observaciones: Vascularización anómala
Imágenes y parámetros obtenidos:



Promedio de parámetros base de datos

Enfermedad	Autocorrelation	Correlation	JointEntropy	JointEnergy	Vasos	Manchas
Sin enfermedad	1.9794	0.8603	0.8382	0.6664	0.9047	1.0725
CNV	3.673	0.8949	1.312	0.5113	1.7103	12.2091
Diabetes	2.0145	0.797	0.8997	0.6592	1.3051	3.9017

Figura 17: Informe generado

7. Bibliografía

- Castillo-Otí, J. M., Cañal-Villanueva, J., García-Unzueta, M. T., Galván-Manso, A. I., Callejas-Herrero, M. R., & Muñoz-Cacho, P. (2020). Prevalencia y Factores de Riesgo Asociados a la retinopatía diabética en santander. Norte de España. Atención Primaria, 52(1), 29–37. <https://doi.org/10.1016/j.aprim.2018.10.001>
- Boyd, K. (2022, September 9). Retinopatía Diabética: Causas, síntomas, Diagnóstico, Tratamiento. American Academy of Ophthalmology. <https://www.aao.org/salud-ocular/enfermedades/retinopatia-diabetica>
- Syna Sreng, Noppadol Maneerat, Hamamoto, K., Ronakorn Panjaphongse. (2018). Automated Diabetic Retinopathy Screening System Using Hybrid Simulated Annealing and Ensemble Bagging Classifier. 8(7), 1198–1198. <https://doi.org/10.3390/app8071198>
- Syna Sreng, Noppadol Maneerat, Isarakorn, D., Hamamoto, K., Ronakorn Panjaphongse. (2017). Primary screening of diabetic retinopathy based on integrating morphological operation and support vector machine. <https://doi.org/10.1109/iciibms.2017.8279750>
- Zhu, Y., Zhang, T., Xu, G., & Peng, L. (2016). Anti-vascular endothelial growth factor for choroidal neovascularisation in people with pathological myopia. Cochrane Database of Systematic Reviews, 2016(12). <https://doi.org/10.1002/14651858.cd011160.pub2>